



République Algérienne Démocratique et Populaire



Ministère de l'Enseignement Supérieur et de la Recherche Scientifique

Université des Sciences et de la Technologie Houari Boumediene

Faculté d'Informatique
Département Informatique

Mémoire de Licence

Filière: Informatique

Spécialité: Ingénierie des Systèmes d'Information et
Logiciels

Détection d'Anomalies Météorologiques Extrêmes
à l'Aide de l'IA et du ML

Sujet Proposé par : *M Azouaou Mellal* **Présenté par :** *AYOUB DJELLAoui*

Soutenu le : *01/06/2024*

Devant le jury composé de:

M GOT ADEL Président
M KHENNAK ILYES Membre

Binôme n° : 087 / 2024

Remerciement

Tout d'abord, je tiens à dire Alhamdoulilah. Je remercie Allah, le tout puissant, pour toute la volonté, la patience et le courage qu'il nous a donnés, afin de pouvoir réaliser ce projet.

Je voudrais exprimer ma profonde gratitude à toutes les personnes et institutions qui m'ont soutenu tout au long de ce projet.

Je remercie ma mère, mon père et toute ma famille, ainsi que ma défunte grand-mère, Maman-Zizou, pour leur soutien constant depuis mon enfance. Leur amour et leurs encouragements m'ont toujours porté et donné la force d'avancer.

Je tiens à remercier particulièrement Monsieur Azouaou Mellal, cofondateur de Tekkolab, qui m'a offert l'opportunité de réaliser un stage au sein de son entreprise. Sa guidance et son aide précieuse, ainsi que le soutien technique et l'environnement de travail stimulant de Tekkolab, ont été essentiels pour la réalisation de ce projet. Leur soutien a grandement contribué à la réussite de ce mémoire.

Je remercie également Monsieur Ilyes Khennak, mon membre de la commission de suivi, qui m'a énormément aidé tout au long de ce travail. Son soutien indéfectible et ses conseils avisés ont été indispensables pour mener à bien ce mémoire. Je ne me vois pas réussir ce projet sans son assistance précieuse.

Je remercie l'ensemble du corps professoral de l'Université des Sciences et des Technologies Houari Boumediene, en particulier les professeurs de mon département, pour leur enseignement de qualité et leur disponibilité tout au long de mon parcours universitaire.

Aux différents membres du jury que nous remercions de nous avoir honorés en acceptant d'examiner notre modeste travail. Veuillez trouver ici l'expression de notre reconnaissance et de notre respect les plus sincères.

Je suis reconnaissant envers mes collègues et amis pour leur soutien moral, leurs encouragements et les discussions enrichissantes que nous avons eues. Leur camaraderie a rendu cette expérience beaucoup plus agréable et motivante.

Je me remercie moi-même d'avoir cru en mes capacités. Je confesse qu'il n'a pas été facile de travailler seul, mais je suis reconnaissant de m'être défié et d'avoir fait de mon mieux, même dans les moments où je n'avais personne d'autre que moi-même. Je sais probablement au fond de mon cœur que je ne suis pas sur le chemin que je voulais emprunter il y a trois ans, mais je suis reconnaissant d'avoir vécu cette expérience à l'USTHB. Elle m'a vraiment façonné en tant qu'individu capable de réaliser n'importe quoi par moi-même, sans avoir besoin de personne.

Nous espérons que ce mémoire est à la hauteur de nos attentes et des attentes de toutes les personnes concernées. Il est, une fois de plus, le fruit des efforts constants de toutes ces personnes qui nous ont aidé et soutenu de près ou de loin. Merci et meilleurs sentiments.

Introduction.....	1
Chapitre 1 : Notions de Base.....	2
1.1 Notions En Intelligence Artificielle et Apprentissage Automatique.....	2
1.1.1 Intelligence Artificielle.....	2
1.1.2 Apprentissage Automatique.....	2
1.1.3 Apprentissage Profond.....	2
1.2 Nettoyage et Prétraitement des Données.....	2
1.2.1 Importance du Nettoyage et du Prétraitement.....	2
1.2.2 Techniques de Nettoyage des Données.....	3
1.2.3 Techniques de Prétraitement des Données.....	3
1.3 Apprentissage Automatique.....	4
1.3.1 Modèles de Classification.....	4
1.3.2 Modèles de Régression.....	5
1.3.3 Modèles de Clustering.....	5
1.3.4 Réseaux de Neurones.....	5
1.3.5 Sous-apprentissage, Sur-apprentissage et Régularisation.....	6
1.1.6 Métriques de Succès pour les Modèles d'Apprentissage Machine.....	6
Chapitre 2 : Phénomènes Météorologiques Extrêmes.....	8
2.1 Définition.....	8
2.2 Types de Phénomènes Météorologiques Extrêmes.....	8
2.3 Conséquences des Phénomènes Météorologiques Extrêmes.....	9
2.4 Impact de la Prévision Météorologique sur Divers Secteurs.....	9
2.5 Les Tornades : Phénomènes Météorologiques Violents.....	10
2.5.1 Définition et Caractéristiques.....	10
2.5.2 Mesure de l'Intensité : L'Échelle de Fujita Améliorée (EF-Scale).....	10
2.5.3 Formation des Tornades : Le Mésocyclone.....	10
2.6 Pourquoi les Tornades ? Pourquoi les États-Unis ?.....	11
2.6.1 Choix des Tornades parmi les Phénomènes Météorologiques Extrêmes.....	11
2.6.2 Les États-Unis : un Terrain d'Étude Privilégié pour les Tornades.....	12
2.7 Problématique : Importance d'un Système de Prédiction Efficace.....	13
2.8 Conclusion.....	13
Chapitre 3 : Analyse et Préparation des Données pour la Prédiction des Tornades.....	14
3.1 Défis de la Prédiction des Données Météorologiques.....	14
3.2 Source de Donnée.....	15
3.2.1 Jeu de Données sur les Tornades.....	15
3.2.2 API de la NOAA.....	15
3.3 Analyse Exploratoire des Données.....	15
3.3.1 Définition et Importance.....	15
3.3.2 Distribution Géographique des Tornades aux États-Unis.....	16
3.3.3 Tendances et Saisonnalité des Tornades.....	17
3.3.4 Analyse des Magnitudes des Tornades.....	18

TABLE DES MATIÈRES

3.3.5 Analyse des Dommages et Pertes Humaines et Matérielles.....	20
3.3.5 Conclusions et Résultats de l'EDA.....	21
3.3.6 Focus sur le Texas.....	21
3.4 Utilisation de l'API de la NOAA.....	22
3.4.1 Raison de l'Utilisation de l'API de la NOAA.....	22
3.4.2 Évaluation et Sélection de la Méthode de Collecte de Données.....	22
3.4.3 Processus de Récupération des Données via l'API de la NOAA.....	23
3.5 Génération et Extraction de Données Non-Tornades.....	25
3.5.1 Processus de Génération de Données pour les Événements Non-Tornades.....	25
3.5.2 Extraction et Intégration des Données dans le Dataset Principal.....	25
3.6 Nettoyage, Prétraitement et Ingénierie des Caractéristiques.....	26
3.6.1 Analyse des Valeurs Manquantes et Nettoyage des Données.....	26
3.6.2 Ingénierie des Caractéristiques Temporelles.....	28
3.6.3 Normalisation et Standardisation.....	29
3.6.4 Analyse des Corrélations.....	29
3.7 Modélisation et Entraînement.....	30
3.7.1 Préparation des Données.....	30
3.7.2 Sélection et Entraînement des Modèles.....	31
3.8 Conclusion.....	32
Chapitre 4 : Résultats, Tests et Analyse des Modèles Prédicatifs.....	33
4.1 Environnement de Développement.....	33
4.1.1 Hardware.....	33
4.1.2 Software.....	33
4.2 Tests Et Résultats.....	33
4.2.1 Support Vector Classifier.....	33
4.2.2 Forêt Aléatoire.....	35
4.2.3 Autres Models.....	37
4.2.4 Recherche par Grille pour la Régression Logistique.....	38
4.2.5 Recherche par Grille pour Les Réseaux de Neurones.....	38
4.3 Conclusion.....	39
Conclusion.....	40
Bibliographie.....	42

TABLE DES FIGURES

Figure 2.1 — Collage de phénomènes météorologiques extrêmes.....	8
Figure 2.2 — Impacts des événements météorologiques extrêmes.....	9
Figure 2.3 — Exemple d'une tornade massive.....	10
Figure 2.4 — Échelle de fujita améliorée.....	10
Figure 2.5 — Formation des tornades.....	10
Figure 2.6 — Phénomène de sept tornades simultanées.....	11
Figure 2.7 — Carte montrant la tornado alley aux États-Unis.....	12
Figure 3.1 — Répartition des tornades aux États-Unis (1950-2022).....	16
Figure 3.2 — Nombre de tornades par état (1950-2022).....	16
Figure 3.3 — Nombre de tornades par an (1950-2022).....	17
Figure 3.4 — Nombre de tornades par an avec ligne de tendance (1950-2022).....	17
Figure 3.5 — Répartition mensuelle des tornades.....	18
Figure 3.6 — Répartition horaire des tornades par heure de la journée.....	18
Figure 3.7 — Tendance des tornades par magnitude.....	18
Figure 3.8 — Magnitudes des tornades par année (1950-2022).....	19
Figure 3.9 — Radars doppler.....	19
Figure 3.10 — Nombre de tornades de magnitude 4-5 par état.....	20
Figure 3.11 — Matrice de corrélation.....	30
Figure 4.1 — Matrice de confusion pour modèle initial vs meilleur modèle.....	34
Figure 4.2 — Comparaison entre le modèle initial et le meilleur modèl.....	34
Figure 4.3 — Comparaison du résultat du validation croisée (meilleur modèl SVC).....	35
Figure 4.4 — Accuracy de modèle forêt aléatoire avec une seule colonne de vent.....	36
Figure 4.5 — Validation croisée après la suppression complète des colonnes de vent.....	37
Figure 4.6 — Rapport de classification pour Le meilleur modèle RN.....	38
Figure 4.7 — Graphique de la validation croisée (10 Plis).....	39

LISTE DES TABLEAUX

Tableau 1.1 — Métriques d'évaluation.....	7
Tableau 3.1 — Pourcentage des valeurs manquantes.....	26
Tableau 3.2 — Résumé de nettoyage des données.....	28
Tableau 4.1 — Rapport de classification pour modèle initial vs meilleur modèle.....	34
Tableau 4.2 — Résultat du validation croisée (meilleur modèle SVC).....	35
Tableau 4.3 — Rapport de classification après la suppression complète des colonnes de vent.....	36
Tableau 4.4 — Validation croisée après la suppression complète des colonnes de vent	36
Tableau 4.5 — Rapport de classification pour d'autres modèles.....	37
Tableau 4.6 — Résultats de la validation croisée (10 Plis).....	39

L'étude et la prédiction des phénomènes météorologiques extrêmes, tels que les ouragans, les tornades, les inondations et les vagues de chaleur, sont d'une importance capitale en raison de leur potentiel destructeur significatif. La précision de ces prédictions est cruciale pour la préparation et la mitigation des effets de ces événements, ce qui souligne l'importance des progrès technologiques dans l'amélioration de la précision prédictive.

Historiquement, la collecte de données météorologiques impliquait des enregistrements sur papier et des serveurs locaux. Aujourd'hui, ces ensembles de données ont migré vers des plateformes cloud ouvertes, permettant une accessibilité plus large et une analyse plus complète. Cette évolution technologique a non seulement amélioré notre compréhension des modèles météorologiques mais a également augmenté la précision et l'efficacité des prédictions.

À mesure que le climat de la Terre continue de changer, la fréquence et l'intensité des événements météorologiques extrêmes augmentent également. Des températures record, des précipitations sévères, des sécheresses prolongées et des ouragans dévastateurs deviennent plus courants et plus intenses, nécessitant des modèles prédictifs robustes pour gérer et atténuer efficacement leurs impacts.

L'Intelligence Artificielle (IA) et l'Apprentissage Automatique (AA) ont révolutionné la manière dont les météorologues prévoient le temps. Ces technologies offrent la capacité d'analyser rapidement et avec précision de vastes quantités de données. Les modèles d'IA peuvent détecter des motifs et prédire des changements dans les conditions météorologiques, améliorant ainsi les capacités prédictives des modèles météorologiques. L'intégration de l'IA dans la prévision météorologique aide non seulement à prévoir le temps mais aussi à comprendre les dynamiques complexes des systèmes météorologiques influencés par le changement climatique.

Dans ce projet nous proposons d'utiliser les techniques de l'IA et de l'apprentissage automatique pour résoudre une sous-catégorie de ce problème, focalisée sur la détection des tornades. Cette démarche spécifique permet d'aborder un aspect particulièrement imprévisible et destructeur des phénomènes météorologiques extrêmes.

Le document est structuré en quatre chapitres principaux :

- **Notions de Base:** Exploration des concepts fondamentaux en intelligence artificielle et en apprentissage automatique, incluant l'importance et les techniques de nettoyage et de prétraitement des données, ainsi que les différents modèles d'apprentissage automatique et leurs métriques de succès.
- **Phénomènes Météorologiques Extrêmes :** Description des divers phénomènes météorologiques extrêmes, avec un focus particulier sur les tornades.
- **Analyse, Préparation des Données et Modélisation :** Processus détaillé de collecte, de nettoyage et de modélisation des données pour la prédiction des tornades.
- **Résultats, Tests et Analyse :** Présentation des résultats des modèles, discussion sur leur efficacité réelle, et perspectives d'intégration dans des systèmes prévisionnels élargis.

En conclusion, ce mémoire envisage des perspectives futures et des améliorations pour renforcer la précision et la fiabilité des prédictions météorologiques, face aux enjeux climatiques en évolution.

Ce chapitre présente les notions essentielles d'intelligence artificielle et d'apprentissage automatique. Nous explorerons également les techniques de nettoyage et de prétraitement des données nécessaires pour préparer les ensembles de données à des fins de modélisation prédictive.

1.1 Notions en Intelligence Artificielle et Apprentissage Automatique

1.1.1 Intelligence Artificielle

L'Intelligence Artificielle (IA) fait référence aux technologies et systèmes capables d'exécuter des tâches complexes en utilisant des algorithmes avancés. Cela inclut des domaines tels que la perception visuelle, la reconnaissance vocale, la prise de décisions et la traduction linguistique. L'IA vise à améliorer et à automatiser diverses fonctions en s'appuyant sur des modèles sophistiqués [1].

1.1.2 Apprentissage Automatique

L'Apprentissage Automatique (ML), une sous-discipline de l'IA, concerne l'étude et le développement d'algorithmes qui permettent aux ordinateurs d'apprendre et de faire des prédictions ou des décisions basées sur des données. Les algorithmes de ML utilisent des données historiques pour identifier des modèles et faire des prédictions sur de nouvelles données, améliorant ainsi leur performance au fil du temps grâce à l'expérience et aux ajustements continus des modèles [1].

1.1.3 Apprentissage Profond

L'Apprentissage Profond, une branche plus avancée de l'apprentissage automatique, utilise des réseaux de neurones avec de nombreuses couches (d'où le terme "profond") pour analyser divers facteurs des données. Cette méthode est particulièrement efficace pour traiter de grands volumes de données présentant des relations non linéaires complexes. Dans les applications météorologiques, l'apprentissage profond peut traiter des données provenant de diverses sources, telles que les satellites et les capteurs au sol, pour détecter des motifs complexes dans les systèmes météorologiques, qui échappent aux modèles météorologiques traditionnels [2].

1.2 Nettoyage et Prétraitement des Données

Le nettoyage des données, consiste à détecter et corriger (ou supprimer) les colonnes corrompues ou inexacts d'un ensemble de données. Ce processus comprend l'identification des parties incomplètes, incorrectes ou non pertinentes des données, puis leur remplacement, modification ou suppression.

1.2.1 Importance du Nettoyage et du Prétraitement

- **Fiabilité des résultats:** Des données de mauvaise qualité peuvent conduire à des modèles biaisés et à des conclusions erronées. Le nettoyage et le prétraitement garantissent que les données sont fiables et représentatives de la réalité.
- **Performance des modèles:** Des données propres et bien préparées améliorent la performance des modèles d'apprentissage automatique, leur permettant d'apprendre des relations significatives et de faire des prédictions plus précises.

- **Efficacité du processus:** Un prétraitement adéquat peut réduire le temps de calcul et optimiser l'utilisation des ressources lors de l'entraînement des modèles.

1.2.2 Techniques de Nettoyage des Données

a. Gestion des Données Manquantes

1. **Suppression:** Éliminer les colonnes avec des valeurs manquantes (approche simple, mais pouvant introduire des biais) [8].
2. **Remplacement par la moyenne/médiane/mode:** Remplacement des valeurs manquantes par la moyenne, la médiane ou le mode de la colonne. Simple et souvent efficace pour les données numériques [8].
3. **Modèles de Prédiction:** Utilisation de modèles statistiques ou d'apprentissage automatique pour prédire et compléter les valeurs manquantes en fonction des autres données disponibles [8].
 - **Régression linéaire:** Pour les variables numériques continues.
 - **K plus proches voisins (KNN):** Pour les variables catégorielles ou numériques.
 - **Arbres de décision:** Pour les variables catégorielles ou numériques.

b. Correction des Erreurs de Données

1. **Règles de validation des données :** Mise en place de contrôles pour vérifier la validité des données (par exemple, l'âge ne peut pas être négatif) pour identifier les erreurs de saisie [8].
2. **Détection des valeurs aberrantes:** Identifier les valeurs atypiques à l'aide de méthodes statistiques (Z-score, écart interquartile - IQR) [8].
 - **Z-score:** Nombre d'écarts-types par rapport à la moyenne.
 - **IQR:** Plage interquartile (Q3 - Q1). Les valeurs situées à l'extérieur de 1,5 fois l'IQR sont souvent considérées comme aberrantes.

1.2.3 Techniques de Prétraitement des Données

a. Mise à l'Échelle des Caractéristiques

Normalisation et **Standardisation** sont deux techniques essentielles pour la mise à l'échelle des caractéristiques, particulièrement importantes pour les modèles qui dépendent de la distance entre les points de données, comme le SVM ou les KNN [13].

1. Normalisation

La normalisation ajuste l'échelle des données à une nouvelle plage, typiquement de 0 à 1, ce qui est utile pour les algorithmes sensibles à l'échelle des données d'entrée.

$$x_{normalisé} = \frac{x - \min(x)}{\max(x) - \min(x)}$$

2. Standardisation

La standardisation redimensionne les données pour avoir une moyenne de 0 et un écart type de 1. Ce processus est également connu sous le nom de normalisation Z-score.

$$x_{\text{standardisé}} = \frac{x - \text{moyenne}(x)}{\text{std}(x)}$$

où "std" représente l'écart-type, une mesure de la dispersion ou de la variabilité des valeurs autour de la moyenne. L'écart-type est calculé comme suit :

$$\text{std}(x) = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \text{moyenne}(x))^2}$$

Où N est le nombre total de valeurs, est x_i chaque valeur individuelle, et $\text{moyenne}(x)$ est la moyenne des valeurs.

b. Transformation des Variables

1. **Logarithmique:** Réduit l'impact des valeurs extrêmes sur la modélisation, souvent utilisée pour des variables asymétriques [14].
2. **Racine carrée:** Réduit l'asymétrie des données, utile pour des données de comptage où la variance augmente avec la moyenne [14].
3. **Box-Cox:** transformation paramétrique ajustant les données pour rapprocher leur distribution de la normalité, utile lorsque d'autres transformations ne suffisent pas [14].

c. Encodage des Variables Catégorielles

1. **One-Hot encoding:** Convertit les variables catégorielles en une série de variables binaires. Chaque catégorie devient une nouvelle colonne, où 1 représente la présence de la catégorie et 0 son absence [10].
2. **Label encoding:** Chaque catégorie est assignée à un numéro unique. Cela peut être utile pour les algorithmes capables de traiter des relations ordinales, mais pourrait être inapproprié pour des modèles comme la régression linéaire où les valeurs numériques ont une signification algébrique [10].
3. **Target encoding:** Chaque catégorie est remplacée par un nombre dérivé de la moyenne de la variable cible pour cette catégorie. Par exemple, dans un contexte de prédiction de fraude, les catégories géographiques pourraient être encodées selon le taux de fraude moyen par région [10].

d. Discrétisation

1. **Binning:** Les valeurs numériques sont divisées en "bacs" ou groupes, qui peuvent être de taille égale ou non. Par exemple, l'âge peut être groupé en décennies: 0-10, 11-20, etc [11].
2. **Quantification:** C'est la transformation de variables numériques en catégories ordinales, souvent basées sur des quantiles. Cela peut aider à réduire l'impact des valeurs aberrantes [11].

1.3 Apprentissage Automatique

1.3.1 Modèles de Classification

Arbres de décision: Un modèle qui utilise une structure arborescente pour prendre des décisions basées sur les valeurs des caractéristiques. Chaque nœud interne représente un test sur une caractéristique, chaque branche représente le résultat du test, et chaque feuille représente une étiquette de classe. Simple à comprendre et à interpréter, mais peut être sujet à l'overfitting [4].

Forêt aléatoire: Utilisé pour classer des données en apprenant des ensembles d'arbres de décision. Chaque arbre donne un vote pour la classe, et la classe avec le plus de votes devient la prédiction du modèle. Utile pour sa robustesse et sa capacité à gérer des ensembles de données de haute dimensionnalité sans overfitting significatif [4].

Machines à vecteurs de support (SVM): Efficaces pour la classification et la régression de données complexes. En classification, les SVM maximisent la marge entre différentes classes, ce qui les rend particulièrement utiles dans la reconnaissance des motifs et les situations où les classes ne sont pas linéairement séparables. En régression, les SVM sont utilisés pour prédire des valeurs continues en minimisant l'erreur de prédiction [4].

Régression logistique: Bien qu'elle porte le nom de régression, elle est largement utilisée pour la classification binaire, comme prévoir la probabilité d'un événement (par exemple, pluie ou pas de pluie) [4].

K-Plus proches voisins (KNN): Ce modèle fait des prédictions pour un nouveau point de données en se basant sur la majorité des labels des K points les plus proches dans l'espace de caractéristiques. Il est simple et efficace pour les problèmes de classification [4].

Naïf bayes: Basé sur le théorème de Bayes, il est particulièrement utile pour les grands ensembles de données. Naive Bayes est souvent utilisé pour la classification de textes et le filtrage de spam [4].

1.3.2 Modèles de Régression

Régression linéaire: Un modèle fondamental pour prédire une variable continue basée sur une ou plusieurs variables indépendantes. Utilisé pour sa simplicité et efficacité dans les problèmes où les relations sont linéaires [4].

Régression ridge: Une extension de la régression linéaire où une pénalité est appliquée sur la taille des coefficients pour réduire l'overfitting et améliorer la généralisation du modèle [4].

1.3.3 Modèles de Clustering

Clustering des k-moyennes: Un algorithme qui partitionne les données en K groupes distincts en minimisant la somme des distances entre les points de données et le centre de leur cluster assigné. Utile pour la segmentation de marché, la segmentation d'image, etc [4].

Clustering hiérarchique: Méthode qui regroupe les données en arbres de clusters basés sur leur proximité ou leur similarité. Approprié pour des tâches où l'on souhaite une hiérarchie de groupements qui peut être tracée, comme dans l'analyse scientifique des données biologiques ou la segmentation du comportement des utilisateurs [4].

1.3.4 Réseaux de Neurones

Les réseaux de neurones appartiennent à la fois au domaine de l'apprentissage machine et à celui de l'apprentissage profond. Ils sont composés de couches de neurones avec des connexions pondérées. Utilisés pour des tâches de classification et de régression, ils sont particulièrement performants sur des données complexes où des modèles linéaires simples échouent. En apprentissage profond, des architectures de réseaux de neurones plus complexes, comme les réseaux convolutifs (CNN) et les réseaux récurrents (RNN), sont employées pour des tâches spécifiques telles que la reconnaissance d'image et le traitement du langage naturel [3].

1.3.5 Sous-apprentissage, Sur-apprentissage et Régularisation

a. Sous-apprentissage

Le sous-apprentissage est un phénomène qui se produit lorsque l'erreur sur l'ensemble de validation et l'ensemble d'entraînement reste élevée et cesse de diminuer. Dans ce cas, le modèle n'est même pas capable de classer correctement les données utilisées durant la phase d'entraînement. Ce problème survient généralement lorsque le modèle est trop simple pour comprendre la complexité des données [9].

b. Sur-apprentissage

À l'opposé du sous-apprentissage, le sur-apprentissage se produit lorsque l'erreur sur l'ensemble d'entraînement diminue tandis que l'erreur sur l'ensemble de validation augmente. Cela signifie que le modèle s'adapte trop bien aux données d'entraînement au point de perdre sa capacité à généraliser sur de nouvelles données. Pour combattre le sur-apprentissage, des techniques telles que la réduction du nombre d'attributs, l'augmentation de la taille de l'ensemble d'entraînement, et la régularisation sont souvent employées [9].

c. Régularisation

La régularisation est une méthode utilisée pour éviter le sur-apprentissage en ajoutant un terme de pénalité à la fonction de coût. Ce terme pénalise les valeurs extrêmes des poids du modèle, aidant ainsi à préserver la généralisation [12].

Régularisation L1 (Lasso) : Ajoute la somme des valeurs absolues des coefficients (norme L1) à la fonction de coût. La formule est généralement exprimée comme suit:

$$E(x) = \frac{1}{2m} \sum_{i=1}^m (y_i - h_0(x_i))^2 + \lambda \sum_{j=1}^n |\theta_j|$$

où :

- $E(x)$ est la fonction de coût totale.
- m est le nombre total d'exemples d'entraînement.
- y_i est la valeur réelle pour l'exemple i .
- $h_0(x_i)$ est la prédiction du modèle pour l'exemple i .
- λ est le paramètre de régularisation qui contrôle l'importance de la pénalisation L1.
- θ_j est le coefficient du j -ème paramètre.
- n est le nombre total de paramètres.

Cette forme de régularisation peut conduire à des modèles où certains poids sont réduits à zéro, offrant ainsi une forme de sélection de caractéristiques automatique. Toutefois, elle n'est pas différentiable partout, ce qui peut poser des défis dans l'application de certains algorithmes d'optimisation.

Régularisation L2 (Ridge) : Ajoute la somme des carrés des coefficients (norme L2) à la fonction de coût. La formule inclut un paramètre de régularisation λ qui contrôle l'ampleur de la pénalité :

$$E(x) = \frac{1}{2m} \sum_{i=1}^m (y_i - h_0(x_i))^2 + \lambda \sum_{j=1}^n \theta_j^2$$

La régularisation L2 est différentiable et tend à donner des résultats où tous les poids sont réduits mais rarement à zéro.

1.1.6 Métriques de Succès pour les Modèles d'Apprentissage Automatique

a. Importance des Métriques d'Évaluation

Dans le domaine de l'apprentissage automatique, évaluer correctement les performances d'un modèle est crucial pour garantir sa fiabilité et son efficacité. Les métriques d'évaluation fournissent des informations essentielles sur la capacité du modèle à faire des prédictions précises et à généraliser à partir de nouvelles données.

Elles permettent également de détecter les problèmes de surajustement ou de sous-ajustement, et d'ajuster les hyperparamètres du modèle pour optimiser ses performances.

Utiliser des métriques diversifiées aide à comprendre différents aspects de la performance d'un modèle, tels que sa précision, sa capacité à éviter les erreurs de classification, et son équilibre entre sensibilité et spécificité [6].

b. Tableau des Métriques d'Évaluation

Métrique	Description	Formule
Exactitude (Accuracy)	Mesure la proportion totale de prédictions correctes.	$\frac{TP + TN}{TP + TN + FP + FN}$
Erreur de Classification	Taux d'erreurs dans les prédictions.	$\frac{FP + FN}{TP + TN + FP + FN}$
Sensibilité (Recall)	Capacité de détecter les positifs.	$\frac{TP}{TP + FN}$
Spécificité	Capacité de détecter les négatifs.	$\frac{TN}{TN + FP}$
Précision (Precision)	Exactitude des prédictions positives.	$\frac{TP}{TP + FP}$
Score F1	Harmonie entre la précision et le rappel.	$2 \times \frac{Precision \times Recall}{Precision + Recall}$
Score F β (où β est un nombre réel non négatif)	Balance entre la précision et le rappel avec un facteur β pour ajuster leur importance relative.	$(1 + \beta^2) \times \frac{Precision \times Recall}{(\beta^2 \times Precision) + Recall}$

Tableau 1.1 — Métriques d'évaluation

Notez que certaines mesures sont connues sous plusieurs noms. TP, TN, FP, FN, P, N font référence respectivement au nombre de vrais positifs, de vrais négatifs, de faux positifs, de faux négatifs, d'échantillons positifs et d'échantillons négatifs.

c. Validation Croisée

La validation croisée à k plis divise les données en k sous-ensembles aléatoires, chacun servant à tour de rôle de test pendant que les autres forment l'ensemble d'entraînement. Chaque échantillon est utilisé une fois comme test et $k-1$ fois pour l'entraînement, offrant ainsi une estimation fiable de la performance du modèle. Cette méthode est particulièrement utile pour s'assurer que le modèle fonctionne bien avec des données indépendantes et pour éviter le surajustement [6].

d. Recherche par Grille

La Recherche par Grille (Grid Search) est une méthode de recherche systématique utilisée pour trouver les meilleurs hyperparamètres d'un modèle d'apprentissage automatique. Cette technique explore de manière exhaustive un espace défini de valeurs de hyperparamètres pour identifier la combinaison optimale qui maximise les performances du modèle. En évaluant toutes les combinaisons possibles de hyperparamètres, la recherche par grille garantit une optimisation précise, bien que souvent coûteuse en termes de temps de calcul [7].

2.1 Définition

Les phénomènes météorologiques extrêmes sont des conditions atmosphériques qui dépassent les normes climatiques habituelles et peuvent entraîner des conséquences sérieuses pour l'environnement, l'économie, et la sécurité publique. Ces événements incluent une large gamme de conditions météorologiques intenses qui sont souvent imprévisibles et difficiles à gérer [19].



Figure 2.1 — Collage de phénomènes météorologiques extrêmes

2.2 Types de Phénomènes Météorologiques Extrêmes

- **Tornades (Tornadoes):** Colonnes d'air en rotation violente reliant le sol à un nuage cumulonimbus, capables de générer des vents extrêmement destructeurs.
- **Inondations (Floods):** Accumulation d'eau sur des terrains normalement secs, souvent due à des précipitations excessives ou à la rupture de barrages, provoquant des dégâts importants.
- **Incendies de forêt (Wildfires):** Feux non contrôlés qui se propagent rapidement sur de vastes zones de végétation, souvent déclenchés par des conditions météorologiques sèches et chaudes, et pouvant causer des destructions massives et des pertes humaines.
- **Blizzards (Blizzards):** Tempêtes de neige avec vents forts et visibilité réduite, entravant gravement les déplacements et les activités quotidiennes.

D'autres types, tels que les **orages**, la **foudre**, les **sécheresses**, les **vagues de chaleur** et la **grêle** présentent également des risques significatifs. Chacun de ces phénomènes a des caractéristiques et des risques uniques, nécessitant des stratégies spécifiques de préparation et de réponse. Comprendre et prédire précisément ces événements est crucial pour minimiser leur impact sur la société et l'environnement [19].

2.3 Conséquences des Phénomènes Météorologiques Extrêmes

Les phénomènes météorologiques extrêmes entraînent des conséquences dévastatrices :

- **Pertes humaines et déplacements de population:** Des milliers de décès et des millions de personnes déplacées chaque année.
- **Dommages matériels et pertes économiques:** Infrastructures détruites, perturbations économiques majeures, coûts de reconstruction colossaux.
- **Impacts environnementaux:** Destruction des écosystèmes, pollution, perturbations des cycles naturels.
- **Crises de ressources:** Pénuries d'eau potable, insécurité alimentaire, menaces pour la santé publique.

Ces événements extrêmes soulignent l'importance cruciale de la prévision et de la prévention pour atténuer leurs impacts dévastateurs sur les sociétés et l'environnement.



Figure 2.2 — Impacts des événements météorologiques extrêmes

2.4 Impact de la Prévision Météorologique sur Divers Secteurs

1. **Agriculture:** Les conditions météorologiques influencent les pratiques agricoles, de la planification des semis à la gestion de l'irrigation. Des données météorologiques fiables aident les agriculteurs à minimiser les pertes dues aux sécheresses, gelées ou inondations.
2. **Transport:** Le secteur des transports, notamment aérien et maritime, dépend fortement des prévisions météorologiques pour assurer la sécurité des voyages et éviter les retards causés par des conditions défavorables.
3. **Énergies renouvelables:** La production d'énergie éolienne et solaire est directement influencée par les conditions météorologiques. Des prévisions précises sont essentielles pour anticiper les fluctuations de production et gérer l'approvisionnement énergétique.
4. **Préparation aux catastrophes:** La prévision météorologique joue un rôle crucial dans la gestion des catastrophes, permettant des évacuations rapides et le déploiement efficace des ressources en cas d'ouragans, d'inondations ou d'autres événements extrêmes.
5. **Tourisme:** L'industrie du tourisme utilise les données météorologiques pour optimiser l'expérience des visiteurs, planifier les activités en fonction des conditions favorables et prévenir les risques liés aux intempéries.

2.5 Les Tornades : Phénomènes Météorologiques Violents

2.5.1 Définition et Caractéristiques

Une tornade est une colonne d'air en rotation violente, reliée au sol et issue d'un nuage d'orage. Ils peuvent générer des vents extrêmement puissants, atteignant jusqu'à **500 km/h**, causant des destructions considérables et des pertes en vies humaines. Cependant, la majorité des tornades sont relativement faibles et se produisent dans des zones peu peuplées [15].



Figure 2.3 — Exemple d'une tornade massive

2.5.2 Mesure de l'Intensité : L'Échelle de Fujita Améliorée (EF-Scale)

L'intensité d'une tornade est estimée en analysant les dommages causés aux structures et à la végétation, puis en corrélant ces dommages avec les vitesses de vent nécessaires pour les produire. L'Échelle de Fujita Améliorée, adoptée en 2007, est utilisée pour classer les tornades en fonction de leur intensité, allant de **EF0** à **EF5** [18].

Catégorie	Vents km/h	Dommages	Description	
EF0	105-137	Légers	Quelques morceaux de recouvrement de toit enlevés (tuile, bardeau d'asphalte, etc.), dommages aux gouttières, cheminées et revêtement de façade, branches cassées, arbres à racines de surface renversés	
EF1	138-178	Modérés	Recouvrement de toit complètement enlevés, maisons mobiles renversées ou endommagées sévèrement, portes extérieures envolées, fenêtres et autres articles en verre cassés.	
EF2	179-218	Considérables	Toits soufflés sur des maisons bien construites, maisons à charpente légère déplacées de leurs fondations, maisons mobiles complètement détruites, gros arbres cassés ou déracinés, objets légers devenus des projectiles, automobiles soulevées.	
EF3	219-266	Sévères	Étages complets de maisons solides détruits, dommages importants aux édifices publics comme les centres commerciaux et les centres d'affaires, trains renversés, arbres écorcés, camions et grosses voitures soulevés et déplacés, bâtiments légers complètement soufflés à distance.	
EF4	267-322	Dévastateurs	Maisons bien construites et maisons à charpente légère détruites, voitures soufflées à distance et nombreux objets transformés en projectiles.	
EF5	>322	Incroyables	Maisons solides rasées et les débris projetés, objets de la grosseur d'une voiture projetés à plus de 100 mètres, gratte-ciels avec des dommages structuraux, etc.	

Figure 2.4 — Échelle de fujita améliorée [22]

2.5.3 Formation des Tornades : Le Mésocyclone

La plupart des tornades se forment au sein d'orages supercellulaires, caractérisés par un mésocyclone, une zone de rotation à l'intérieur de l'orage. L'interaction complexe de l'air chaud et humide ascendant avec l'air froid et sec descendant peut entraîner la formation d'un entonnoir nuageux qui, en touchant le sol, devient une tornade [16].




Figure 2.5 — Formation des tornades

2.6 Pourquoi les Tornades ? Pourquoi les États-Unis ?

2.6.1 Choix des Tornades parmi les Phénomènes Météorologiques Extrêmes

Les tornades se distinguent par plusieurs caractéristiques qui en font un sujet d'étude crucial :

1. **Puissance dévastatrice:** Les tornades peuvent causer des dégâts matériels et humains considérables en un temps très court et sur une zone limitée.
2. **Imprévisibilité:** Leur formation rapide et soudaine rend leur prévision difficile, limitant le temps disponible pour les alertes et les mesures de protection.
3. **Fréquence d'occurrence et variabilité régionale:** Les tornades se produisent plus fréquemment dans certaines régions, offrant une base de données unique pour étudier leurs caractéristiques spécifiques et leurs mécanismes de formation.
4. **Défis scientifiques:** Malgré les avancées technologiques, la prédiction précise des tornades reste un défi majeur, nécessitant une meilleure compréhension de leur développement et de leur évolution.



Figure 2.6 — Phénomène de sept tornades simultanées

En choisissant de nous concentrer sur les tornades, nous avons cherché à apporter une contribution significative à la réduction de leur impact dévastateur. L'objectif est double :

1. **Faire progresser la recherche scientifique:** En améliorant notre compréhension des tornades, nous pourrions développer des modèles prédictifs plus précis et fiables.
2. **Sauver des vies et protéger les biens:** En fournissant des outils concrets pour anticiper et mieux gérer ces événements extrêmes, nous pouvons aider les communautés à se préparer et à réagir efficacement, minimisant ainsi les pertes humaines et matérielles.

2.6.2 Les États-Unis : un Terrain d'Étude Privilégié pour les Tornades

Les États-Unis offrent un contexte unique et favorable à l'étude approfondie des tornades :

1. **Haute fréquence et intensité:** Les États-Unis enregistrent le plus grand nombre de tornades au monde, notamment dans la "*Tornado Alley*", offrant une abondance de données pour la recherche.
2. **Diversité des tornades:** Le pays connaît une grande variété de tornades en termes de taille, de durée et d'intensité, permettant d'étudier tous les aspects de ces phénomènes.
3. **Infrastructure de recherche avancée:** Les États-Unis disposent de radars Doppler de pointe, de réseaux de stations météorologiques et de programmes de recherche dédiés, facilitant l'étude et la prévision des tornades.
4. **Impact socio-économique élevé:** Les tornades ont un impact considérable sur les vies humaines et l'économie américaine, soulignant la nécessité de développer des systèmes de prédiction efficaces.




Figure 2.7 — Carte montrant la tornado alley aux États-Unis

En nous concentrant sur les États-Unis, nous pouvons exploiter ces atouts pour approfondir notre compréhension des tornades et développer des stratégies de prévention et d'intervention plus efficaces, contribuant ainsi à réduire l'impact dévastateur de ces phénomènes météorologiques extrêmes.

2.7 Problématique : Importance d'un Système de Prédiction Efficace

Améliorer la prévision des tornades est un défi majeur pour la météorologie moderne, compte tenu de leur nature destructrice et imprévisible. Un système de prédiction efficace est essentiel pour :

1. **Sauver des vies** : Des alertes précoces permettent aux populations de se mettre à l'abri et de prendre les mesures de sécurité nécessaires.
2. **Réduire les dégâts matériels** : Anticiper l'intensité et la trajectoire des tornades permet de protéger les infrastructures et l'agriculture.
3. **Optimiser les secours d'urgence** : Des prévisions précises facilitent le déploiement stratégique des équipes et des ressources dans les zones à risque.
4. **Renforcer la préparation communautaire** : Des informations fiables et régulières permettent aux communautés de mieux se préparer et de réagir efficacement face aux tornades.
5. **Faire progresser la recherche** : Les données collectées et analysées contribuent à affiner les modèles de prévision et à mieux comprendre les tornades.
6. **Améliorer la gestion des risques** : Des prévisions plus précises permettent aux assureurs et aux planificateurs de mieux évaluer et gérer les risques liés aux tornades.

En développant des systèmes de prédiction plus performants, notamment grâce à l'intelligence artificielle et aux nouvelles technologies, nous pouvons réduire considérablement l'impact dévastateur des tornades et mieux protéger les populations et les biens.

2.8 Conclusion

Ce chapitre a posé les bases nécessaires à notre étude. Les tornades, phénomènes météorologiques extrêmes à la fois fascinants et dévastateurs, ont été présentés en détail, soulignant les défis liés à leur prédiction et l'importance de mieux les comprendre pour protéger les vies humaines et les biens. Nous avons également mis en évidence l'intérêt de se concentrer sur les États-Unis, compte tenu de la fréquence élevée et de la diversité des tornades qui y sévissent, ainsi que des ressources disponibles pour la recherche. Une fois les modèles prédictifs développés et validés aux États-Unis, ces approches pourront être adaptées et appliquées à d'autres régions du monde, offrant ainsi une portée globale à notre travail.

Ce chapitre se concentre sur la préparation et le traitement des données nécessaires à la modélisation des tornades. Nous abordons les étapes de nettoyage des données, l'ingénierie des caractéristiques, et la sélection des modèles pour assurer la qualité et la pertinence des données utilisées.

3.1 Défis de la Prédiction des Données Météorologiques

La prédiction des tornades est un défi majeur en raison de :

1. **Variabilité des conditions météorologiques** : Les paramètres atmosphériques peuvent changer rapidement, rendant difficile la prédiction précise.
2. **Précision des prévisions** : Les modèles actuels ont des limites en termes de précision, en particulier pour prédire des événements spécifiques comme les tornades.
3. **Qualité et disponibilité des données** : Les données météorologiques historiques peuvent être incomplètes ou imprécises, avec des valeurs manquantes ou des variables absentes.
4. **Contraintes computationnelles** : L'entraînement de modèles complexes nécessite des ressources de calcul importantes, ce qui peut limiter les approches possibles.

Pour relever ces défis, nous avons utilisé :

1. **Données historiques et actuelles** : Combinaison de données de tornades historiques et de données météorologiques en temps réel de l'API NOAA. Même si cela a été extrêmement difficile et chronophage, nécessitant de parcourir des dizaines de gigaoctets de données pour trouver les bonnes informations, le temps investi dans cette recherche de données s'est avéré être l'un des meilleurs investissements de ce projet.
2. **Techniques de nettoyage des données** : Gestion des valeurs manquantes et correction des erreurs pour garantir la qualité des données.
3. **Modèles d'apprentissage automatique** : Utilisation d'algorithmes adaptés pour apprendre des relations complexes dans les données et améliorer la précision des prévisions.

3.2 Source de Donnée

Pour notre projet de prédiction des tornades, nous avons utilisé deux sources principales de données: un jeu de données historique sur les tornades et une API pour obtenir des données météorologiques actuelles.

3.2.1 Jeu de Données sur les Tornades

Nous avons téléchargé le jeu de données sur les tornades couvrant la période de 1950 à 2022 depuis le site web du National Weather Service (NWS) Storm Prediction Center (SPC). Ce jeu de données comprend des rapports détaillés sur les tornades, tels que la date, l'heure, la magnitude, les pertes, la largeur, la longueur, les points de départ et d'arrivée.

- Lien de téléchargement: [NOAA SPC Tornado Data](#)
- Lien de la documentation: [SPC Severe Weather Database Description](#)
- Description du dataset: Le dataset contient 68,693 entrées avec 27 colonnes, y compris om, yr, mo, dy, date, time, tz, datetime utc, st, stf, mag, inj, fat, loss, slat, slon, elat, elon, len, wid

3.2.2 API de la NOAA

En complément des données historiques, nous avons utilisé l'API Climate Data Online (CDO) du National Centers for Environmental Information (NCEI) pour obtenir des données météorologiques actuelles. Cette API fournit un accès aux données météorologiques et climatiques actuelles, ce qui est crucial pour la prédiction des événements météorologiques extrêmes.

- Documentation de l'API: [NOAA CDO Web Services Documentation](#)
- Description: L'API permet d'accéder aux données météorologiques par requête en utilisant des coordonnées géographiques (latitude et longitude) et d'obtenir des informations telles que la température, la vitesse du vent, les précipitations, etc.

3.3 Analyse Exploratoire des Données

3.3.1 Définition et Importance

L'Analyse Exploratoire des Données (EDA) est essentielle dans tout projet de traitement des données. Elle permet d'examiner les données brutes pour comprendre leur structure, détecter les anomalies, identifier les tendances et préparer les données pour des analyses ultérieures. L'EDA utilise des techniques statistiques et des visualisations pour offrir une vue d'ensemble des données et des insights précieux. Elle permet de :

- **Comprendre les données** : Se familiariser avec le jeu de données, comprendre les variables et leurs distributions, et les relations entre elles.
- **Identifier les tendances et patterns** : Repérer les tendances temporelles et spatiales, cruciales pour les analyses futures.
- **Détecter les anomalies** : Repérer les valeurs aberrantes et les anomalies qui pourraient affecter les analyses.
- **Préparer les données** : Traiter les valeurs manquantes, normaliser les données et sélectionner les caractéristiques pertinentes.

Dans notre projet d'analyse des tornades, l'EDA a été réalisée sur le jeu de données couvrant la période de 1950 à 2022. Cette étape a été cruciale pour comprendre la saisonnalité et les tendances des tornades et pour préparer les données pour des analyses futures.

3.3.2 Distribution Géographique des Tornades aux États-Unis

a. Occurrence des Tornades aux États-Unis

Pour commencer, nous avons examiné la distribution géographique des tornades à travers les États-Unis. Cela permet de visualiser les zones les plus touchées par les tornades et de mieux comprendre leur répartition spatiale.

Occurrences de Tornades aux États-Unis (1950-2022)




Figure 3.1 — Répartition des tornades aux États-Unis (1950-2022)

Comme le montre la carte ci-dessus, la distribution des tornades est principalement concentrée au centre des États-Unis et un peu à l'est. Cette concentration indique les zones les plus vulnérables aux tornades.

b. Distribution par État

Ensuite, nous avons analysé la distribution des tornades par état pour identifier quels états sont les plus touchés.




Figure 3.2 — Nombre de tornades par état (1950-2022)

Le graphique ci-dessus montre que les tornades ne sont pas distribuées de manière uniforme par rapport à la superficie terrestre ou à la population. Les états avec le plus grand nombre de tornades sont le Texas (TX), le Kansas (KS), l'Oklahoma (OK), la Floride (FL), et le Nebraska (NE), qui font partie de la Tornado Alley, ainsi que la Floride.

c. Tornado Alley

Cette concentration élevée dans certains états est due à la Tornado Alley, une région des États-Unis où les tornades sont particulièrement fréquentes. La Tornado Alley s'étend généralement du nord du Texas à travers l'Oklahoma, le Kansas, le Nebraska, et jusqu'au Dakota du Sud. Cette région est sujette à des tornades fréquentes en raison de la convergence de l'air chaud et humide provenant du golfe du Mexique avec l'air froid et sec des Rocheuses [17].

3.3.3 Tendances et Saisonnalité des Tornades

a. Augmentation Annuelle des Tornades




Figure 3.3 — Nombre de tornades par an (1950-2022)

Il semble que le nombre de tornades observées annuellement soit en augmentation. Pour mieux comprendre cette tendance, nous avons ajouté un **modèle linéaire** pour voir ce qu'il révèle.




Figure 3.4 — Nombre de tornades par an avec ligne de tendance (1950-2022)

Notre modèle linéaire présente un coefficient de détermination (r^2) de 0,62 et une pente de 12,4. Cela signifie qu'il y a en moyenne 12,4 tornades de plus chaque année, ce qui semble considérable.

b. Saisonnalité Mensuelle des Tornades




Figure 3.5 — Répartition mensuelle des tornades

Les données montrent une saisonnalité mensuelle marquée, avec la majorité des tornades se produisant au printemps et en été, surtout en **Mai** et **Juin**.

c. Heure de la Journée des Tornades

Les tornades peuvent se produire à tout moment, mais surviennent principalement l'après-midi et en début de soirée, atteignant un pic en fin d'après-midi.




Figure 3.6 — Répartition horaire des tornades par heure de la journée

3.3.4 Analyse des Magnitudes des Tornades

a. Distribution des Magnitudes




Figure 3.7 — Tendance des tornades par magnitude

L'analyse des magnitudes des tornades montre que les tornades moins sévères dominent les données. La majorité des tornades enregistrées ont une magnitude de 0 ou 1, tandis que les tornades de magnitude supérieure sont beaucoup moins fréquentes.

b. Tendances par Magnitude

Les données montrent une hausse marquée des tornades de magnitude 0 et 1 jusqu'au début des années 2000, puis une légère baisse. Pour les tornades de magnitude 2, une légère baisse est observée, tandis qu'il n'y a pas de variation significative pour les tornades de magnitude 3, 4 et 5.




Figure 3.8 — Magnitudes des tornades par année (1950-2022)

c. Impact des Radars Doppler

Il semble y avoir une tendance à la baisse du nombre de tornades de catégorie plus élevée et une tendance à la hausse du nombre de tornades de catégories plus faibles. Cependant, il est important de noter que l'augmentation des tornades de plus faible intensité peut être liée à l'évolution des technologies de détection.



Figure 3.9 — Radars doppler

Entre 1980 et 2000, les réseaux de radars météorologiques conventionnels ont été remplacés par des **radars Doppler**, qui offrent une meilleure capacité de détection des phénomènes météorologiques. Cette amélioration a conduit à une détection accrue des tornades moins sévères, ce qui explique en partie la tendance à la hausse des tornades de faible magnitude. En d'autres termes, l'augmentation apparente des tornades de faible intensité pourrait être due à une meilleure détection plutôt qu'à une véritable augmentation de leur occurrence.[20]

d. Distribution par État des Tornades de Forte Magnitude

Nous avons également analysé la répartition par état des tornades de magnitude 4 et 5 pour identifier les états les plus touchés par les tornades les plus sévères.




Figure 3.10 — Nombre de tornades de magnitude 4-5 par état

Les États avec le plus grand nombre de tornades de magnitude 4 et 5 sont l'Oklahoma (OK) et le Texas (TX), suivis par l'Iowa (IA) et le Kansas (KS).

3.3.5 Analyse des Dommages et Pertes Humaines et Matérielles

L'analyse des dommages et des pertes humaines et matérielles causés par les tornades est essentielle pour comprendre leur impact sur les communautés. Cette section examine les années et les états les plus touchés en termes de blessures, de décès et de pertes financières.




Figure 3.11 — Statistiques des années et des états ayant le plus de blessés, de décès et de pertes économiques (1950-2022)

a. Années les Plus Impactées par les Blessures et les Décès

De 1950 à 2022, les années les plus impactées par les blessures dues aux tornades sont 2004, 2008, 2011, 2017 et 2019. Les états les plus touchés par les blessures sont le Texas (TX), le Kansas (KS), l'Oklahoma (OK), la Floride (FL) et le Nebraska (NE).

Les années les plus impactées par les décès sont 1952, 1953, 1965, 1974 et 2011. Les états les plus touchés par les décès sont l'Alabama (AL), le Texas (TX), le Mississippi (MS), l'Oklahoma (OK) et le Tennessee (TN).

b. Pertes Financières

Les tornades causent également des pertes financières significatives. Les années avec les plus grandes pertes financières (en milliards de dollars) sont 1974, 1980, 2011, 2013 et 2019. Les États les plus impactés par les pertes financières sont le Texas (TX), l'Alabama (AL), l'Oklahoma (OK), le Missouri (MO) et l'Indiana (IN).

3.3.5 Conclusions et Résultats de l'EDA

En résumé, l'EDA a fourni des insights précieux pour comprendre la distribution, la saisonnalité et l'impact des tornades aux États-Unis. Les analyses ont révélé plusieurs points clés :

- **Distribution Géographique** : Les tornades sont principalement concentrées dans le centre des États-Unis, avec une forte densité dans la Tornado Alley, particulièrement au Texas.
- **Saisonnalité** : Les tornades se produisent principalement au printemps et en été, avec un pic en mai et juin. La plupart des tornades surviennent l'après-midi et en début de soirée.
- **Tendances Temporelles** : Une tendance à la hausse du nombre de tornades observées annuellement a été notée, influencée par l'amélioration des technologies de détection.
- **Magnitude** : Les tornades de moindre intensité (magnitude 0 et 1) dominent les données, tandis que les tornades de forte intensité sont moins fréquentes mais causent des dommages plus importants.

3.3.6 Focus sur le Texas

Les résultats de l'EDA montrent que le Texas est l'État le plus touché par les tornades en termes de nombre total d'occurrences, de blessures, de décès et de pertes financières. En particulier :

- **Nombre de Tornades** : Le Texas enregistre le plus grand nombre de tornades parmi tous les états.
- **Impacts Humains** : Le Texas a le plus grand nombre de blessures et de décès causés par les tornades.
- **Pertes Financières** : Les pertes financières dues aux tornades sont les plus élevées au Texas.

L'analyse exploratoire des données (EDA), réalisée sur un ensemble initial d'environ 70 000 entrées, a révélé une concentration des tornades dans quelques États, notamment le Texas, justifiant ainsi notre décision de focaliser l'étude sur cet état. Ce focus sur les 9 000 tornades texanes permettra de mieux comprendre les facteurs météorologiques locaux influençant leur formation, d'optimiser les efforts de prédiction dans cette région particulièrement vulnérable et de maximiser l'impact pratique de nos résultats en améliorant la préparation et la réponse aux tornades.

3.4 Utilisation de l'API de la NOAA

3.4.1 Raison de l'Utilisation de l'API de la NOAA

Pour prédire les tornades, des données météorologiques détaillées étaient essentielles. Le jeu de données principal sur les tornades (1950-2022) fournissait uniquement des informations sur les occurrences, telles que la date, l'heure, la magnitude et les points de départ et d'arrivée, mais pas les conditions météorologiques précédant les tornades.

L'API de la NOAA (National Oceanic and Atmospheric Administration) a comblé cette lacune en permettant de récupérer des données météorologiques précises aux dates et lieux des tornades. Ces données incluent la température, la vitesse du vent, les précipitations et la pression atmosphérique. Grâce à l'API, il est possible d'accéder directement aux données par longitude et latitude, offrant ainsi une base solide pour l'analyse et la modélisation des tornades.

3.4.2 Évaluation et Sélection de la Méthode de Collecte de Données

a. Approches Utilisées

Pour identifier les facteurs météorologiques contribuant à la formation des tornades, nous avons testé deux approches sur des échantillons aléatoires de **50** à **100** tornades texanes :

1. **Association avec la station météorologique la plus proche:** En utilisant la formule de Haversine, nous avons identifié les trois stations texanes les plus proches de chaque tornade et extrait les données correspondantes, en priorisant la station la plus proche.
2. **Récupération directe via l'api de la NOAA:** Utilisation des coordonnées géographiques de chaque tornade pour interroger directement l'API de la NOAA et obtenir les données météorologiques spécifiques à cet emplacement.

b. Comparaison des Approches Utilisées

L'approche initiale présentait des limites :

- **Imprécision des données:** Les conditions météorologiques peuvent varier considérablement sur de courtes distances, et les stations météorologiques peuvent être éloignées de plusieurs kilomètres, rendant les données moins précises.

En revanche, la récupération directe des données via l'API de la NOAA offrait des avantages décisifs :

- **Précision accrue:** Utilisation des coordonnées exactes de la tornade pour obtenir des données spécifiques à cet emplacement.
- **Plus grande disponibilité des données:** Large éventail de données météorologiques disponibles, incluant des mesures radar et satellitaires.
- **Algorithme d'association optimisé:** Probablement plus sophistiqué que la simple distance géographique, prenant en compte d'autres facteurs comme le type de données ou les conditions topographiques.

c. Validation et Choix de l'Approche

Comparant les deux méthodes, nous avons constaté un faible taux de correspondance (33%) entre les données de la station la plus proche et celles de l'API de la NOAA, confirmant l'imprécision de la première approche. Nous avons donc retenu la récupération directe des données via l'API de la NOAA, garantissant des données plus précises, fiables et complètes pour notre analyse. Cette approche a été essentielle pour construire un modèle de prédiction robuste basé sur des informations météorologiques de haute qualité.

2.4.3 Processus de Récupération des Données via l'API de la NOAA

Après avoir choisi l'API NOAA comme source principale de données météorologiques, nous avons entrepris une démarche méthodique pour identifier les types de données les plus pertinents pour mon modèle de prédiction de tornades et optimiser le processus de récupération des données.

a. Exploration et Sélection Initiale des Types de Données

Nous avons commencé par explorer l'ensemble des 1567 types de données disponibles via l'API NOAA, documentant leurs descriptions et leurs formats dans un fichier CSV. Après une analyse minutieuse, nous avons sélectionné les types de données qui semblaient les plus susceptibles d'influencer la formation des tornades, les regroupant par catégories :

1. **Données de température, précipitations et chutes de neige:** TMAX, TMIN, PRCP, SNOW
2. **Données de couverture nuageuse:** ACMC, ACMH, ACSC, ACSH
3. **Données de vitesse du vent:** AWND, WSF1, WSF2, WSF5, WSFG, WSFI, WSFM
4. **Données de direction du vent:** WDF1, WDF2, WDF5, WDFG, WDFI, WDFM
5. **Données d'événements liés au vent:** WT03, WT11, WT10, PGTM
6. **Données de point de rosée et d'indice de chaleur:** HLY-DEWP-10PCTL, HLY-DEWP-90PCTL, HLY-DEWP-NORMAL, HLY-HIDX-NORMAL
7. **Données de pression au niveau de la mer:** HLY-PRES-10PCTL, HLY-PRES-90PCTL, HLY-PRES-NORM
8. **Données de réflectivité radar:** N0Q, N1Q, N2Q, N3Q, NAQ, NBQ, NCZ, NCR, N0R, N1R, N2R, N3R, N0Z, NSS, NST, NTV, NMD, NME

b. Tests de Récupération

Pour évaluer la qualité et la disponibilité des données, nous avons effectué des tests de récupération sur des échantillons aléatoires de 50 à 100 tornades texanes.

Fonction RECUPERER DONNEES METEO(session, clé api, latitude, longitude, date, types données):

Cette fonction récupère les données météorologiques pour une latitude, une longitude et une date spécifiques en utilisant l'API NOAA.

1. Préparer la requête pour l'API NOAA avec les paramètres donnés.
2. Envoyer la requête et réessayer en cas d'erreur.
3. Si la requête réussit, extraire et retourner les données météorologiques.
4. Sinon, retourner des valeurs manquantes (None).

Fonction RECUPERER DONNEES METEO CONCURRENT(data frame, clés api, types données):

Cette fonction envoie des requêtes simultanées pour récupérer les données météorologiques pour plusieurs entrées dans un data frame, en utilisant différentes clés API pour équilibrer la charge.

1. Créer une session de requêtes.
2. Pour chaque ligne du data frame, appeler la fonction **RECUPERER DONNEES METEO** pour envoyer des requêtes simultanées en utilisant différentes clés API.
3. Récupérer les résultats et les ajouter au dataframe.

Approches de récupération et résultats

- **Approche 1: Récupération groupée:** Nous avons tenté de récupérer l'ensemble des types de données sélectionnés en une seule requête par l'intermédiaire de la fonction **RECUPERER DONNEES METEO CONCURRENT**, mais cela a entraîné un grand nombre de valeurs manquantes, nécessitant une fonction de récupération récursive pour combler les lacunes.
- **Approche 2: Récupération par catégorie:** Nous avons divisé les types de données en catégories et effectué des requêtes séparées pour chaque catégorie. Cette stratégie a permis de réduire considérablement le nombre de valeurs manquantes. Pour chaque catégorie, nous avons analysé le pourcentage de valeurs manquantes par type de données et avons exclu ceux présentant plus de 60% de valeurs manquantes.

Après chaque récupération, nous avons systématiquement vérifié le nombre de valeurs manquantes pour chaque type de données dans l'échantillon:

Pour chaque type de données dans liste types des données:

1. Compter le nombre de valeurs manquantes (NaN) dans la colonne correspondante du dataframe.
2. Afficher le nombre de valeurs manquantes pour ce type de données.

Exemples de résultats:

Les résultats de ces tests ont montré une grande variabilité dans la disponibilité des données selon les types. Par exemple :

- **Données fiables:** Les types de données **TMAX** (température maximale), **TMIN** (température minimale) et **PRCP** (précipitations) étaient systématiquement disponibles pour toutes les tornades de l'échantillon (aucun NaN). Par exemple, le type de données **WSFG** (rafale de vent maximale) présentait un taux de valeurs manquantes relativement faible (environ 6%), ce qui le rendait également fiable pour l'analyse.
- **Données peu fiables:** De nombreux types de données liés à la réflectivité radar (par exemple, **N0Q**, **N1Q**, etc.) présentaient un taux de valeurs manquantes de 100%, indiquant leur absence dans les données historiques pour les tornades étudiées.

Nous avons répété ces tests sur plusieurs échantillons aléatoires pour m'assurer que les résultats n'étaient pas biaisés et pour confirmer la fiabilité des types de données sélectionnés.

c. Sélection Finale des Types de Données

Après ces tests, nous avons retenu les types de données suivants, organisés par catégorie, pour la collecte finale :

1. **Température, précipitations et chutes de neige:** TMAX, TMIN, PRCP, SNOW
2. **Couverture nuageuse:** ACMC, ACMH, ACSC, ACSH
3. **Vitesse du vent:** AWND, WSF1, WSF2, WSF5, WSFG, WSFI, WSFM
4. **Direction du vent:** WDF1, WDF2, WDF5, WDFG, WDFI, WDFM
5. **Événements liés au vent:** WT03, WT11, WT10, PGTM

d. Récupération Finale des Données

Une fois la sélection affinée, nous avons récupéré les données météorologiques pour l'ensemble des tornades du Texas en utilisant les coordonnées (latitude et longitude) de chaque événement et en effectuant des requêtes parallèles par catégorie via la fonction **RECUPERER DONNEES METEO CONCURRENT** pour optimiser le processus.

3.5 Génération et Extraction de Données Non-Tornades

Pour entraîner un modèle de prédiction capable de distinguer entre les événements tornades et non-tornades, il était essentiel de générer un ensemble de données non-tornades équilibré. Cela permet de fournir au modèle des exemples de situations où une tornade ne s'est pas produite, afin d'éviter le biais dans les prédictions.

3.5.1 Processus de Génération de Données pour les Événements Non-Tornades

Pour créer un ensemble de données de non-tornades, nous avons développé une fonction **CREER DATAFRAME NON TORNADES** qui génère des points de données aléatoires à l'intérieur des frontières du Texas et à des dates où aucune tornade n'a été enregistrée. Voici le processus détaillé que nous avons suivi :

1. Définir les plages de dates et de coordonnées :

- **Plage de dates** : 1950-01-01 à 2022-12-31
- **Plage de latitudes** : 25.8371 à 36.5007 (approximation pour le Texas)
- **Plage de longitudes** : -106.6456 à -93.5083 (approximation pour le Texas)

2. Créer des dates et coordonnées aléatoires :

- Générer une série de dates aléatoires à partir de la plage de dates définie, en excluant les dates où des tornades se sont produites.
- Générer des coordonnées aléatoires (latitude et longitude) dans les plages définies.

3. Construire le data frame non-tornades :

- Créer un DataFrame avec des identifiants négatifs pour distinguer les entrées non-tornades.
- Remplir les colonnes de la même manière que le DataFrame des tornades réelles, en utilisant des valeurs fictives pour les colonnes telles que 'mag' (magnitude), 'inj' (injuries), 'fat' (fatalities), etc.

4. Équilibrage des classes :

- Pour éviter tout biais dans mon modèle prédictif, nous avons vérifié que les classes "tornade" et "non-tornade" étaient équilibrées dans mon jeu de données final. Le nombre d'événements non-tornadiques a été ajusté pour correspondre au nombre de tornades enregistrées.

Voici le Pseudo Code utilisé pour générer le DataFrame non-tornades :

Fonction CREER DATAFRAME NON TORNADES(df tornades, taille, plage dates, plage latitudes, plage longitudes):

1. Générer des dates aléatoires en excluant les dates de tornades.
2. Générer des coordonnées aléatoires (latitude, longitude) à l'intérieur des limites du Texas.
3. Créer un dataframe avec les colonnes appropriées.
4. Remplir le data frame avec les dates, coordonnées et valeurs par défaut pour les non-tornades.
5. Retourner le dataframe.

3.5.2 Extraction et Intégration des Données dans le Dataset Principal

- Il était crucial de vérifier que les dates générées pour les événements non-tornades ne chevauchent pas celles des tornades réelles. Cela a été vérifié. Une fois le dataframe des événements non-tornadiques généré, elles ont été stockées dans un fichier CSV.
- Nous avons utilisé la même méthode que pour les tornades (récupération directe via l'API NOAA) pour extraire les données météorologiques correspondantes à chaque événement. Nous avons ainsi obtenu un ensemble de données complet et équilibré, prêt à être utilisé pour l'entraînement de mon modèle.

3.6 Nettoyage, Prétraitement et Ingénierie des Caractéristiques

Cette section décrit les étapes de nettoyage, prétraitement, et ingénierie des caractéristiques des données de tornades et non-tornades du Texas. L'objectif est de préparer un ensemble de données propre et cohérent pour l'entraînement du modèle.

2.5.3 Analyse des Valeurs Manquantes et Nettoyage des Données

a. Vérification des Valeurs Manquantes

Avant la modélisation, il faut vérifier les valeurs manquantes. La table suivante résume les pourcentages de valeurs manquantes pour chaque type de données pour les événements de tornades et non-tornades.

Datatype	Definition	Tor Data Nan Values %	Non Tor Data Nan %	Datatype	Definition	Tor Data Nan Values %	Non Tor Data Nan %
TMAX TMIN	Max & Min Temperature	0.00%	0.00%	PRCP	Daily precipitation	0.00%	0.00%
WSFM	Fastest mile wind speed	50.03%	57.67%	SNOW	Snowfall	15.56%	23.25%
AWND	Average daily wind speed	40.54%	45.34%	WDFM	Fastest mile wind direction	50.03%	57.67%
WSFI	Highest instantaneous wind speed	52.29%	53.61%	WSFG	Peak gust wind speed	7.22%	6.89%
WDFG	Direction of peak wind gust	7.22%	6.89%	PGTM	Peak gust time	5.98%	0.00%
WSF1	Fastest 1-minute wind speed	49.60%	57.41%	WSF2	Fastest 2-minute wind speed	56.62%	59.31%
WSF5	Fastest 5-second wind speed	56.62%	59.31%	WDF1	Direction of fastest 1-minute wind	49.60%	57.41%
WDF2	Direction of fastest 2-minute wind	56.62%	59.31%	WDF5	Direction of fastest 5-second wind	56.62%	59.31%
WDFI	Direction of highest instantaneous wind	77.79%	80.44%	WT03	Thunder	0.00%	0.87%
WT11	High or damaging wind	23.73%	21.01%	WT10	Tornado, waterspout, or funnel cloud	85.84%	90.09%
ACMH	Average cloudiness midnight to midnight from manual observations	34.16%	44.23%	ACSH	Average cloudiness sunrise to sunset from manual observations	34.16%	44.23%
ACMC	Average cloudiness midnight to midnight from 30-second ceilometer data	99.76%	99.67%	ACSC	Average cloudiness sunrise to sunset from 30-second ceilometer data	99.15%	99.47%

Tableau 3.1 — Pourcentage des valeurs manquantes

b. Raisons pour Supprimer Certaines Colonnes

- **ACMC et ACSC:** Ces colonnes ont des pourcentages de valeurs manquantes très élevés (près de 100%). De plus, elles sont redondantes avec ACMH et ACSH, qui fournissent des informations similaires mais avec moins de valeurs manquantes. Par conséquent, les colonnes ACMC et ACSC ont été supprimées.
- **PGTM:** Le temps de la rafale de vent la plus élevée ne varie pas de manière significative d'un jour à l'autre et n'est pas essentiel pour la modélisation.
- **WT10:** Cette colonne indique si un événement de type tornade s'est produit. Étant donné que notre objectif est de prédire les tornades, cette information n'est pas disponible a priori pour la prédiction et est donc supprimée.

c. Traitement des Valeurs Manquantes

Pour les colonnes restantes, différentes stratégies ont été adoptées pour gérer les valeurs manquantes :

- **SNOW:** Les valeurs manquantes ont été remplacées par 0, car la neige n'est pas une caractéristique dominante dans la région étudiée et les valeurs uniques étaient soit 0 soit NaN.
- **Colonnes en degrés (direction du vent):** Pour les colonnes de direction du vent (WDF1, WDF2, WDF5, WDFI, WDFM), une conversion en radians suivie d'une transformation sinusoïdale a été utilisée pour l'interpolation linéaire des valeurs manquantes, ensuite reconverties en degrés.
- **AWND, WSFG, WDFG, ACMH, ACSH, WT11:** Les valeurs manquantes ont été remplacées par la médiane des valeurs non manquantes de la colonne correspondante.
- **WT03 dans les données non-tornades:** Les valeurs manquantes ont été remplacées par 0 car les valeurs uniques étaient soit 0 soit 1, ce qui indique probablement l'absence de l'événement.
- Après le nettoyage des données, les données ont été sauvegardées pour une utilisation ultérieure dans le processus de modélisation.

d. Remplacement des Valeurs Manquantes par Modèle

Pour améliorer la précision du remplacement des valeurs manquantes, nous avons utilisé des modèles de régression.

Remplacement des Valeurs Manquantes pour 'mag' (Magnitude):

- Nombre de Valeurs Manquantes: 146
- Modèle Utilisé: *Random Forest Regressor*
- Caractéristiques Utilisées: 'len' (longueur) et 'wid' (largeur)
- Processus: Les valeurs manquantes de 'mag' ont été prédites avec un Random Forest Regressor, en utilisant 'len' et 'wid' comme caractéristiques explicatives.

Remplacement des Valeurs Manquantes pour 'loss':

- Nombre de Valeurs Manquantes: 4662
- Modèle Utilisé: *Random Forest Regressor*
- Caractéristiques Utilisées: 'mag', 'fat' (nombre de morts), et 'inj' (nombre de blessés)
- Processus: Les valeurs manquantes de 'loss' ont été prédites avec un Random Forest Regressor, en utilisant 'mag', 'fat', et 'inj' comme caractéristiques explicatives.

Ces modèles capturent les relations complexes entre les caractéristiques, permettant un remplacement précis. Les valeurs prédites sont intégrées dans le jeu de données pour le rendre complet et prêt pour la modélisation.

e. Résumé de Nettoyage des Données

Datatype	Action
TMAX, TMIN, PRCP	Aucun traitement nécessaire
SNOW, WT03	Remplacement par 0
AWND, WSFG, WDFG, ACMH, ACSH, WT11	Remplacement par la médiane
WDF1, WDF2, WDF5, WDFI, WDFM	Interpolation cyclique et backfill/forward fill
ACMC, ACSC, PGTM, WT10	Colonnes supprimées
Mag, Loss	Remplacement des valeurs par modèle

Tableau 3.2 — Résumé de nettoyage des données

3.6.2 Ingénierie des Caractéristiques Temporelles

L'ingénierie des caractéristiques temporelles est essentielle pour capturer les variations et les patterns influençant les tornades. Voici les principales transformations appliquées :

a. Extraction des Composantes Temporelles

Les colonnes temporelles fournissent des informations précieuses sur l'heure, la date, et le moment de la journée où les tornades se produisent. Les transformations suivantes ont été appliquées :

- Extraction de l'heure et des minutes à partir de 'time' (HH:MM:SS).
- Création de 'part_of_day' (Night, Morning, Afternoon, Evening) en utilisant la technique de **discrétisation**.
- Conversion de 'date' en datetime pour extraire 'year', 'month', 'day', 'day_of_week', et 'is_weekend' (Une colonne binaire indiquant si la date est un weekend, utilisant la **binarisation**).

b. Encodage des Mois et des Périodes de la Journée

Pour permettre au modèle de comprendre les données temporelles de manière efficace, les colonnes catégorielles ont été encodées :

- Encodage des mois en colonnes binaires (**One-Hot encoding**) : 'month_1' à 'month_12'.
- Encodage des périodes de la journée : 'part_of_day_Night', 'part_of_day_Morning', 'part_of_day_Afternoon', 'part_of_day_Evening'.

c. Traitement des Colonnes Temporelles

Les transformations suivantes ont été appliquées pour préparer les données pour l'analyse et la modélisation :

- Conversion de 'time' et 'datetime_utc' en datetime pour extraire l'heure et les minutes.
- Conversion des colonnes binaires résultantes en type entier.

3.6.3 Normalisation et Standardisation

La mise à l'échelle des données est cruciale pour que toutes les caractéristiques contribuent équitablement à la modélisation. Nous avons choisi la standardisation, qui transforme les données pour avoir une moyenne de zéro et un écart-type de un, utile pour les données à distribution gaussienne comme les données météorologiques.

a. Raisons de la Standardisation

- **Consistance de l'Échelle** : Chaque caractéristique contribue également aux calculs de distance, essentiel pour les modèles sensibles à l'échelle.
- **Traitement des Différentes Unités** : Uniformise les mesures en différentes unités (ex. vitesse du vent en m/s, température en °C).
- **Gestion des Valeurs Extrêmes** : Réduit l'impact des valeurs aberrantes, fréquentes dans les événements météorologiques extrêmes.

b. Processus de Standardisation

1. **Concaténation des données** : Combinaison des ensembles de données de tornades et de non-tornades pour une application uniforme de la standardisation.
2. **Mélange des données** : Mélange aléatoire pour éviter les biais potentiels.
3. **Identification des colonnes à mettre à l'échelle** : Colonnes numériques continues identifiées pour la mise à l'échelle. Colonnes standardisées : TMAX, TMIN, PRCP, AWND, WSFI, WSFM, WSFG, WDFG, WSF1, WSF2, WSF5, WDF1, WDF2, WDF5, WDFI, WDFM, ACMH, ACSH, WT03, WT11.
4. **Application de la standardisation** : Utilisation de **StandardScaler** de *scikit-learn* pour transformer les données en calculant la moyenne et l'écart-type de chaque caractéristique.

En standardisant ces colonnes, nous avons assuré une échelle comparable pour toutes les caractéristiques, améliorant ainsi la performance des algorithmes de modélisation.

3.6.4 Analyse des Corrélations

Analyser les corrélations aide à comprendre les relations entre les variables du dataset, crucial pour la modélisation et la prédiction des tornades.

a. Calcul de la Matrice de Corrélation

Pour commencer, les colonnes non numériques, en particulier les colonnes de date ou de temps, ont été supprimées pour se concentrer uniquement sur les données numériques. Ensuite, les colonnes redondantes ont également été supprimées. La matrice de corrélation a été calculée en utilisant la méthode de corrélation de Pearson, qui mesure la force et la direction de la relation linéaire entre deux variables.

La matrice de corrélation a été générée pour toutes les variables numériques restantes afin de visualiser les relations entre elles. Cela a permis de détecter des modèles sous-jacents et des relations potentielles entre les différentes variables météorologiques.

b. Visualisation de la Matrice de Corrélation

La matrice de corrélation a été visualisée à l'aide d'une carte thermique (heatmap). Les couleurs de la heatmap indiquent la force et la direction des corrélations, facilitant l'identification des corrélations positives et négatives.




Figure 3.11 — Matrice de corrélation

c. Identification des Paires de Variables Fortement Corrélées

Un seuil de corrélation de **0.8** a été utilisé pour identifier les variables fortement corrélées. Comme il était difficile de remarquer ces corrélations à l'œil nu, nous avons créé une fonction qui détecte et retourne les paires de variables corrélées. Ces paires indiquent une redondance potentielle ou une forte relation linéaire.

L'identification des corrélations élevées est cruciale pour plusieurs raisons :

- **Réduction de la Redondance** : Les variables fortement corrélées fournissent souvent des informations similaires. Réduire cette redondance simplifie le modèle et évite les problèmes de multicollinéarité.
- **Amélioration de la Précision** : En sélectionnant les variables les plus pertinentes et en éliminant celles redondantes, on améliore la précision et l'efficacité du modèle de prédiction.

d. Résultats de l'Analyse des Corrélations

L'analyse a révélé des corrélations élevées entre certaines variables, par exemple, entre *ACMH* et *ACSH* (corrélation de 0.82). En raison de cette corrélation élevée, la colonne *ACSH* a été supprimée pour éviter la redondance.

3.7 Modélisation et Entraînement

3.7.1 Préparation des Données

Après avoir nettoyé et prétraité nos données, nous avons combiné les ensembles de données des occurrences de tornades et des non-tornades. Nous avons ensuite standardisé les caractéristiques continues afin d'assurer une échelle uniforme pour les algorithmes d'apprentissage automatique. Une fois cette étape terminée, nous avons séparé nos données en ensembles d'entraînement et de test, en veillant à maintenir un ratio de **80/20** pour garantir une évaluation équitable des modèles.

3.7.2 Sélection et Entraînement des Modèles

Nous avons testé plusieurs modèles d'apprentissage automatique pour prédire les occurrences de tornades. Chaque modèle a été évalué sur un ensemble de tests et, si nécessaire, des recherches de grille ont été effectuées pour optimiser leurs hyperparamètres.

a. Machines à Vecteurs de Support (SVM) :

Nous avons utilisé le Support Vector Classifier (SVC), un type de SVM, pour classifier les occurrences de tornades. Le modèle SVC a montré des résultats prometteurs avec une précision notable. Pour améliorer les performances, nous avons utilisé la méthode de recherche en grille pour identifier les meilleurs hyperparamètres.

Voici le pseudo code décrivant le fonctionnement de l'algorithme SVM:

Initialisation : Sélectionner la fonction noyau (par exemple, 'linéaire', 'polynomiale', 'RBF'), le paramètre de régularisation (C), et le niveau de tolérance

Étape 1 : Construire l'hyperplan

- Pour SVC linéaire : Trouver les poids optimaux (w) et le biais (b) pour maximiser la marge entre les classes
- Pour SVC non linéaire : Transformer les données en utilisant la fonction noyau pour trouver l'hyperplan optimal dans un espace de dimension supérieure

Étape 2 : Classification des nouveaux points de données

- Si $\text{fonction_noyau}(w * x_{\text{nouveau}} + b) \geq 0$, classer comme **tornado**
- Sinon, classer comme **non-tornado**

Sortie :

- Paramètres du modèle (w et b) et Prédictions pour les données de test

b. Forêt Aléatoire:

Le modèle Random Forest présente un problème de surapprentissage, affichant une précision parfaite sur l'ensemble de test. Pour remédier à ce problème, nous avons limité les caractéristiques du vent à une seule colonne à la fois, ce qui a permis d'améliorer les performances. **Voici le Pseudo Code de Random Forest :**

Initialisation : Sélectionner le nombre d'arbres (n trees) et d'autres hyperparamètres

Pour chaque arbre de la forêt (n trees):

Étape 1 : Échantillonner avec remplacement *les données des tornades au Texas (df tx)*

Étape 2 : Construire un arbre de décision

- Sélectionner un sous-ensemble aléatoire de caractéristiques pour chaque division
- Diviser le nœud en fonction de la meilleure caractéristique et du seuil pour minimiser l'impureté
- Répéter jusqu'à ce que la profondeur maximale soit atteinte ou que les nœuds feuilles soient purs

Étape 3 : Agréger les prédictions de tous les arbres

- Pour la classification : Utiliser le vote majoritaire parmi les arbres
- Pour la régression : Utiliser la prédiction moyenne de tous les arbres

Sortie : Ensemble d'arbres de décision (forêt)

c. Réseaux de Neurones :

Nous avons testé les réseaux de neurones artificiels pour leur capacité à capturer des relations complexes dans les données. Nous avons utilisé une architecture de réseau de neurones avec plusieurs couches cachées et avons ajusté les hyperparamètres à l'aide de la recherche en grille.

Pseudocode des Réseaux de Neurones :

Initialisation : Définir l'architecture du réseau de neurones (nombre de couches, neurones par couche)
Définir les hyperparamètres (taux d'apprentissage, fonction d'activation, etc.)

Pour chaque époque :

Étape 1 : Propagation avant - Calculer les prédictions en utilisant *les données des tornades au Texas (df_tx)*

- Pour chaque couche du réseau :
- Calculer la somme pondérée des entrées et appliquer la fonction d'activation

Étape 2 : Calculer la perte - Mesurer la différence entre les prédictions et les valeurs réelles

Étape 3 : Rétropropagation - Mettre à jour les poids pour minimiser la perte

- Calculer les gradients de la perte par rapport à chaque poids
- Ajuster les poids en utilisant les gradients et le taux d'apprentissage

Répéter pour le nombre d'époques spécifié ou jusqu'à la convergence

Sortie : Modèle de réseau de neurones entraîné

d. Autres Modèles :

Nous avons également testé d'autres modèles, tels que la régression logistique, les arbres de décision, le gradient boosting, XGBoost, AdaBoost, et k-NN. Ces modèles ont donné des résultats modérés ou moyens, avec les modèles basés sur les arbres présentant souvent un surapprentissage similaire à celui observé avec le Random Forest.

3.8 Conclusion

Ce chapitre a détaillé le processus de préparation des données, crucial pour garantir des prédictions de tornades précises. Nous avons effectué un nettoyage rigoureux des données, y compris l'imputation des valeurs manquantes et l'ingénierie des caractéristiques pour enrichir nos ensembles de données.

La sélection et l'entraînement des modèles ont permis d'identifier plusieurs approches prometteuses pour la prédiction des tornades. Malgré le surapprentissage observé avec certains modèles basés sur les arbres, nous avons trouvé des solutions pour atténuer ce problème. Nous avons évalué plusieurs modèles, notamment SVC et les réseaux de neurones, en optimisant leurs hyperparamètres pour améliorer les performances. Les efforts pour atténuer les problèmes de sur-apprentissage avec les modèles basés sur les arbres ont été particulièrement significatifs.

Dans le chapitre suivant, nous analyserons les performances des différents modèles et discuterons des résultats obtenus, ainsi que des stratégies d'amélioration pour affiner nos prédictions de tornades.

Ce chapitre présente les résultats des modèles prédictifs testés pour la prédiction des tornades. Nous discuterons des performances de chaque modèle, des tests effectués pour évaluer leur précision, ainsi que des analyses des résultats obtenus. Cette analyse permettra d'identifier les modèles les plus efficaces et les stratégies d'amélioration potentielles.

4.1 Environnement de Développement

4.1.1 Hardware

Pour l'entraînement des modèles et le traitement des données, nous avons utilisé **Google Colab**, une plateforme qui offre des ressources de calcul puissantes en ligne. Cela nous a permis d'accéder à des *GPU* et des *TPU* pour accélérer les processus d'entraînement des modèles.

4.1.2 Software

Le développement de ce projet a été réalisé principalement en Python, en utilisant un ensemble de bibliothèques spécialisées pour le traitement des données et l'apprentissage automatique. Voici les principales bibliothèques utilisées:

- **Pandas** : Pour la manipulation et l'analyse des données.
- **NumPy** : Pour les opérations mathématiques et la gestion des tableaux.
- **Scikit-learn** : Pour l'entraînement des modèles de machine learning, y compris SVC, RandomForest, réseaux de neurones et autres.
- **Matplotlib, Seaborn** : Pour la visualisation des données.
- **XGBoost** : Pour l'implémentation de l'algorithme de boosting.
- **AdaBoost** : Pour les modèles de boosting adaptatifs.

En utilisant ces outils, nous avons pu effectuer des analyses approfondies des données, entraîner et évaluer divers modèles de prédiction, et visualiser les résultats de manière efficace.

4.2 Tests Et Résultats

4.2.1 Support Vector Classifier

Dans cette section, nous examinons le processus et les résultats de la formation et de l'évaluation du (SVC) sur notre ensemble de données. Nous avons utilisé le SVC avec sa configuration initiale, puis une version optimisée après avoir appliqué la méthode de *recherche par grille* pour trouver les meilleurs hyperparamètres.

a. Modèle Initial

Initialement, nous avons formé le modèle SVC avec un noyau *linéaire*. Ce modèle a donné une précision de **0.8589**. La matrice de confusion du modèle initial est présentée ci-dessous, ainsi qu'un tableau et un graph comparant l'accuracy et le rapport de classification entre le modèle initial et le modèle optimisé.

b. Modèle Optimisé

Pour améliorer les résultats, nous avons utilisé la méthode de *recherche par grille* pour ajuster les hyperparamètres du SVC. Les meilleurs hyperparamètres trouvés étaient : C=10, kernel='rbf', gamma='auto'. Le modèle optimisé a atteint une précision de **0.9045**.

a. Comparaison du Modèle Initial et du Meilleur Modèle




Figure 4.1 — Matrice de confusion pour modèle initial vs meilleur modèle

b. Résultats du Modèle SVC — Initial et Meilleur

Modèle	Accura cy	Precision (Class 0)	Recall (Class 0)	F1-Score (Class 0)	Precision (Class 1)	Recall (Class 1)	F1-Score (Class 1)
Modèle SVC initial	0.865	0.88	0.85	0.87	0.85	0.88	0.86
Meilleur Modèle SVC	0.904	0.90	0.91	0.91	0.91	0.89	0.90

Tableau 4.1 — Rapport de classification pour modèle initial et meilleur modèle




Figure 4.2 — Comparaison entre le modèle initial et le meilleur modèle

c. Validation Croisée

Pour valider davantage la robustesse du modèle optimisé, nous avons effectué une validation croisée avec des CV de 5 et 10. Les résultats montrent une précision moyenne de 0.907 pour CV-5 et 0.912 pour CV-10.

Validation Croisée	Scores de Précision pour Chaque Plis	Précision Moyenne
CV-5	[0.90447922, 0.91095521, 0.91122504, 0.90420939, 0.90393956]	0.9069616837560712
CV-10	[0.90879655, 0.90717755, 0.91527253, 0.91851052, 0.91689153, 0.91797086, 0.90232056, 0.91635186, 0.90663788, 0.91203454]	0.912196438208311

Tableau 4.2 — Résultat du validation croisée (meilleur modèle SVC)




Figure 4.3 — Comparaison du résultat du validation croisée (meilleur modèle SVC)

4.2.2 Forêt Aléatoire

Dans cette section, nous examinons la formation et l'évaluation du modèle *Random Forest* pour la prédiction des tornades. Le modèle *Random Forest* a initialement présenté un problème de sur-apprentissage (*overfitting*). Pour résoudre ce problème, différentes méthodes ont été testées :

- Suppression d'une colonne de vent à la fois (présente encore un surapprentissage)
- Suppression des colonnes de vent par catégorie (présente encore un surapprentissage)
- Suppression des événements WT* (orages, vents violents) (présente encore un surapprentissage)
- Utilisation d'une seule colonne de vent
- Suppression complète des colonnes de vent

a. Utilisation d'une Seule Colonne de Vent

Après plusieurs tentatives, la solution efficace était d'utiliser une seule colonne liée au vent à la fois. Voici les précisions obtenues pour chaque colonne de vent testée :




Figure 4.4 — Accuracy de modèle forêt aléatoire avec une seule colonne de vent

b. Précision Après la Suppression Complète des Colonnes de Vent

Voici les résultats de précision du modèle après la suppression complète des colonnes de vent :

	Precision	Recall	F1-Score	Support
0.0	0.91	0.90	0.91	1897
1.0	0.90	0.91	0.90	1809
Accuracy			0.90	3706
Macro avg	0.90	0.90	0.90	3706
Weighted avg	0.90	0.90	0.90	3706

Tableau 4.3 — Rapport de classification après la suppression complète des colonnes de vent

c. Validation Croisée

Les résultats de la validation croisée pour le modèle *Random Forest* après la suppression complète des colonnes de vent sont présentés ci-dessous :

Validation Croisée	Scores de Précision pour Chaque Plis	Précision Moyenne
CV-5	[0.9101, 0.9174, 0.9172, 0.9045, 0.9217]	0.9142
CV-10	[0.9099, 0.9050, 0.9110, 0.9196, 0.9115, 0.9228, 0.9050, 0.9077, 0.9261, 0.9158]	0.9134

Tableau 4.4 — Validation croisée après la suppression complète des colonnes de vent




Figure 4.5 — Validation croisée après la suppression complète des colonnes de vent

d. Conclusion

Malgré les problèmes initiaux de sur apprentissage – bien que cela ressemble à un sur-apprentissage, nous ne pouvons pas l'affirmer à 100 %, le modèle *Random Forest* a été optimisé en utilisant une seule colonne de vent à la fois. La suppression de toutes les colonnes de vent a également donné une précision acceptable. La validation croisée a confirmé la robustesse du modèle optimisé.

4.2.3 Autres Modèles

Nous avons testé plusieurs modèles pour la prédiction des tornades, notamment la régression logistique, les arbres de décision, le Gradient Boosting, l'AdaBoost, le XGBoost, les k-plus proches voisins (k-NN), et les réseaux de neurones. Les résultats obtenus avec ces modèles sont résumés dans le tableau ci-dessous :

Modèle	Précision	Rappel	F1-Score	Support
Logistic Regression	0.8569	0.86	0.86	3706
Decision Tree	0.9959	1.00	1.00	3706
Gradient Boosting	0.9984	1.00	1.00	3706
XGBoost	0.9987	1.00	1.00	3706
AdaBoost	0.9984	1.00	1.00	3706
k-NN	0.7652	0.77	0.76	3706
Neural Network	0.8538	0.85	0.85	3706

Tableau 4.5 — Rapport de classification pour d'autres modèles

4.2.4 Recherche par Grille pour la Régression Logistique

Nous avons remarqué que le modèle de régression logistique avait des performances assez bonnes. Pour tenter d'améliorer ces résultats, nous avons utilisé la recherche en grille (*Grid Search*) pour optimiser les hyperparamètres de ce modèle.

- **Les meilleurs hyperparamètres trouvés étaient :** *C*: 10, *max_iter*: 1000, *penalty*: l1, et *solver*: liblinear.

Après optimisation, la précision de la régression logistique était de **0.8608**. Le rapport de classification montrait une précision de **0.88** pour *la classe 0.0* et de **0.84** pour *la classe 1.0*, avec un **f1-score de 0.86** pour les deux classes. L'accuracy globale était de **0.86**, avec une **moyenne macro de 0.86** pour la précision, le recall, et le f1-score.

Ces résultats montrent que la régression logistique, même après optimisation, n'a pas significativement amélioré sa précision par rapport à la version initiale du modèle. Cependant, elle reste un modèle solide et simple à interpréter.

4.2.5 Recherche par Grille pour Les Réseaux de Neurones

Les réseaux de neurones ont montré des signes prometteurs lors des tests initiaux avec d'autres modèles, mais les résultats n'étaient pas suffisants pour se démarquer. Pour explorer pleinement leur potentiel, nous avons utilisé la recherche en grille (*Grid Search*) pour optimiser les hyperparamètres du modèle de réseau de neurones, ce qui a abouti à une amélioration significative des performances.

Initialement, le modèle de réseau de neurones (*MLPClassifier*) a donné une précision de **0.85**. Cependant, après l'optimisation des hyperparamètres, les résultats ont été considérablement améliorés.

- **Les meilleurs hyperparamètres trouvés étaient :** *Activation*: 'tanh', *Alpha*: 0.05, *Hidden Layer Sizes*: (100,) *Learning Rate*: 'constant', *Solver*: 'adam'

Les résultats après l'optimisation montrent une précision de **0.9656**. Le rapport de classification est le suivant : pour *la classe 0.0*, précision de **0.98**, rappel de **0.95**, F1-score de **0.97** avec un support de **2791** ; pour *la classe 1.0*, précision de **0.95**, rappel de **0.98**, F1-score de **0.97** avec un support de **2768**. L'accuracy globale est de **0.97**, avec une macro moyenne et une moyenne pondérée de précision, rappel et F1-score toutes à **0.97**, pour un support total de **5559**. Le graphique ci-dessous visualise les résultats :




Figure 4.6 — Rapport de classification pour le meilleur modèle RN

Nous avons également utilisé la validation croisée pour évaluer la robustesse du modèle optimisé. En utilisant une validation croisée à 10 plis, nous avons obtenu les résultats suivants:

Validation Croisée	Scores de Précision pour Chaque Plis	Précision Moyenne	Écart-Type des Scores de Validation Croisée
CV-10	[0.9687, 0.9649, 0.9369, 0.9579, 0.9655, 0.9622, 0.9628, 0.9655, 0.9509, 0.9741]	0.9609	0.0099

Tableau 4.6 — Résultats de la validation croisée (10 Plis)




Figure 4.7 — Graphique de la validation croisée (10 Plis)

l'optimisation des hyperparamètres des réseaux de neurones a considérablement amélioré la précision de notre modèle, le rendant le plus performant parmi tous les modèles testés. Cette approche a permis de capturer les relations complexes dans les données et de fournir des prédictions plus précises des occurrences de tornades.

4.3 Conclusion

Nous avons commencé par tester le modèle SVC, qui a donné des résultats prometteurs. Ensuite, nous avons testé le modèle Random Forest, qui a présenté un problème de sur-apprentissage. Bien que cela ressemble à un sur-apprentissage, nous ne pouvons pas l'affirmer à 100 % en raison de la complexité des données météorologiques et de la variabilité des tornades.

Ensuite, nous avons testé divers modèles tels que les arbres de décision, le Gradient Boosting, et la régression logistique. Parmi ces modèles, la régression logistique et les réseaux de neurones ont montré des signes de bonnes performances. Après avoir appliqué la recherche en grille sur ces deux modèles, la régression logistique n'a pas montré d'amélioration significative. En revanche, le réseau de neurones optimisé a montré une précision exceptionnellement élevée de 0.9656, confirmée par une validation croisée à 10 plis.

Ces résultats mettent en évidence le potentiel des réseaux de neurones pour la prédiction des tornades, surpassant les autres modèles testés.

Conclusion

Dans ce mémoire, nous avons entrepris une étude approfondie sur la prédiction des tornades en utilisant des techniques d'apprentissage automatique. Le projet a impliqué plusieurs étapes cruciales, y compris la collecte et le nettoyage des données, l'ingénierie des caractéristiques, la sélection et l'optimisation des modèles, ainsi que l'évaluation des performances des modèles prédictifs. Nous avons utilisé des données historiques sur les tornades et avons enrichi ces données avec des caractéristiques météorologiques supplémentaires obtenues via l'API NOAA pour améliorer la précision de nos prédictions.

Nos résultats ont montré que les réseaux de neurones, après optimisation des hyperparamètres, ont fourni les meilleures performances avec une précision de 0.9656. En revanche, les modèles comme le Random Forest ont montré des signes de sur-apprentissage, bien que nous ne puissions pas l'affirmer de manière définitive en raison de la complexité des données météorologiques et des caractéristiques inhérentes à ces modèles. Les fluctuations dans les conditions météorologiques et la variabilité des événements extrêmes peuvent avoir contribué à cette apparence de surapprentissage. Les modèles linéaires comme la régression logistique ont montré des performances stables mais n'ont pas atteint la même précision que les réseaux de neurones après optimisation, soulignant l'importance de capturer les non-linéarités dans les données pour des prédictions plus précises.

Bien que notre étude se concentre sur la prédiction des tornades, l'objectif ultime est d'améliorer la réponse des autorités et d'optimiser le dispatching des ressources en cas de tornade. Cela inclut l'optimisation du temps de réponse des ambulances et des services d'urgence, ainsi que la planification optimale des chemins pour éviter les zones dangereuses. À l'avenir, nous prévoyons d'intégrer ces prédictions dans des systèmes de gestion des urgences plus larges pour améliorer la sécurité publique et réduire les pertes en vies humaines et les dommages matériels lors de phénomènes météorologiques extrêmes. En outre, nous envisageons de développer des modèles capables de fournir des alertes en temps réel et de simuler différents scénarios d'intervention, ce qui permettrait aux autorités de mieux préparer et coordonner leurs actions. L'intégration de ces systèmes avec des infrastructures de communication et de transport intelligentes pourrait également améliorer l'efficacité des opérations de secours et minimiser les risques pour les équipes d'intervention et la population.

En conclusion, notre travail a jeté les bases d'un système de prédiction des tornades précis et fiable, et ouvre la voie à des améliorations continues pour mieux protéger les communautés contre ces catastrophes naturelles. Les résultats obtenus et les perspectives d'avenir montrent le potentiel des techniques d'apprentissage automatique pour transformer notre capacité à prévoir et à réagir aux phénomènes météorologiques extrêmes.

1. Goodfellow, I., Bengio, Y., & Courville, A. (2016). Apprentissage Profond. MIT Press.
2. LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436-444.
3. IBM. (2021). What is a neural network? Disponible à : [Lien](#) (Consulté en mai 2024).
4. Tavasoli, S. (2024). Essential machine learning algorithms: Top 10 to master in 2024. Simplilearn. Disponible à : [Lien](#) (Consulté en mai 2024).
5. GeeksforGeeks. (2023). Hierarchical clustering in data mining. Disponible à : [Lien](#) (Consulté en mai 2024).
6. Han, J., Pei, J., & Tong, H. (2022). *Data Mining: Concepts and Techniques* (4th ed.). Morgan Kaufmann Publishers.
7. Lutins, E. (2017). Grid searching in machine learning: Quick explanation and python implementation. Medium. Disponible à : [Lien](#) (Consulté en mai 2024).
8. Dhar, A. (2023). A comprehensive guide to data cleaning techniques. Medium. Disponible à : [Lien](#) (Consulté en mai 2024).
9. T., S.A. (2023). What is overfitting, underfitting & regularization? Medium. Disponible à : [Lien](#) (Consulté en mai 2024).
10. Jain, A. (2024) Label encoding and one- hot encoding, Medium. Disponible à : [Lien](#) (Consulté en mai 2024).
11. Shelar, V. (2023). From numbers to meaning: Unveiling patterns through discretization and binarization of numerical data. Medium. Disponible à : [Lien](#) (Consulté en mai 2024).
12. GeeksforGeeks. (2024). Regularization in Machine Learning. Disponible à : [Lien](#) (Consulté en mai 2024).
13. GeeksforGeeks. (2021). Normalization vs. Standardization. Disponible à : [Lien](#) (Consulté en mai 2024).
14. FasterCapital. (no date). Transformer les variables pour répondre à l'hétéroscédasticité. Disponible à : [Lien](#) (Consulté en mai 2024).
15. Snow, J. (2024). Tornado. Encyclopædia Britannica. Disponible à : [Lien](#) (Consulté en mai 2024).
16. Snow, J. (2024). Tornado formation. Encyclopædia Britannica. Disponible à : [Lien](#) (Consulté en mai 2024).
17. Snow, J. (2024). Tornado Alley. Encyclopædia Britannica. Disponible à : [Lien](#) (Consulté en mai 2024).
18. Snow, J. (2024). Tornado intensity. Encyclopædia Britannica. Disponible à : [Lien](#) (Consulté en mai 2024).

BIBLIOGRAPHIE

19. NOAA National Severe Storms Laboratory. (2024). Severe Weather 101. Disponible à : [Lien](#) (Consulté en mai 2024).
20. Austin, N. (2021). What is Doppler radar? FreightWaves. Disponible à : [Lien](#) (Consulté en mai 2024).
21. NOAA National Weather Service. (2024). Tornadoes - Nature's Most Violent Storms. Disponible à : [link](#) (Consulté en mai 2024).
22. Kreitz, M. (équipe ENM). (no date). Pour en savoir plus: Comment évaluer la vitesse des tornades. Chasseurdetornades. Disponible à : [Lien](#) (Consulté en mai 2024).